

E-Commerce Customer Churn Prediction: Comparative Analysis and Deployment of Machine Learning Models with SHAP-Based Interpretability

**Bootcamp Machine Learning and AI for
Beginner**

Khalisha Haura Zahra



Outline

Project Workflow

- 01 Business Understanding
- 02 Data Understanding
- 03 Data Preparation
- 04 Modeling
- 05 Evaluation
- 06 Conclusion
- 07 Deployment

Business Understanding

Background

Persaingan



Pertumbuhan e-commerce meningkatkan **persaingan** serta memberikan pelanggan lebih banyak pilihan produk, harga, dan layanan.

Risiko Churn



Banyaknya pilihan memudahkan pelanggan berpindah ketika kebutuhan tidak terpenuhi. Kondisi ini meningkatkan **risiko customer churn**.

Dampak



Churn dapat **menurunkan pendapatan & customer lifetime value**, sementara biaya memperoleh pelanggan baru umumnya lebih besar.

Solusi



Perlu **memprediksi potensi churn** sejak dini dan **memahami faktor pengaruhnya** untuk strategi retensi tepat sasaran.

(Fauziyyah et al., 2026; Chajia et al., 2026).

Business Understanding

Rumusan Masalah dan Tujuan

Problem Statement

- 01 Bagaimana mendeteksi pelanggan yang berpotensi churn?
- 02 Fitur apa saja yang paling berkontribusi terhadap prediksi churn?



Objective

- 01 Membangun dan mengevaluasi model machine learning untuk memprediksi pelanggan yang berpotensi churn.
- 02 Mengidentifikasi fitur yang paling berkontribusi terhadap prediksi churn menggunakan SHAP (SHapley Additive exPlanations).

Data Understanding

Deskripsi Dataset

Tipe Data

#	Column	Non-Null Count	Dtype
0	CustomerID	5630 non-null	int64
1	Churn	5630 non-null	int64
2	Tenure	5366 non-null	float64
3	PreferredLoginDevice	5630 non-null	str
4	CityTier	5630 non-null	int64
5	WarehouseToHome	5379 non-null	float64
6	PreferredPaymentMode	5630 non-null	str
7	Gender	5630 non-null	str
8	HourSpendOnApp	5375 non-null	float64
9	NumberOfDeviceRegistered	5630 non-null	int64
10	PreferredOrderCat	5630 non-null	str
11	SatisfactionScore	5630 non-null	int64
12	MaritalStatus	5630 non-null	str
13	NumberOfAddress	5630 non-null	int64
14	Complain	5630 non-null	int64
15	OrderAmountHikeFromlastYear	5365 non-null	float64
16	CouponUsed	5374 non-null	float64
17	OrderCount	5372 non-null	float64
18	DaySinceLastOrder	5323 non-null	float64
19	CashbackAmount	5630 non-null	float64

01

Ukuran Dataset

Total Baris: **5.630** | Total Kolom: **20**

02

Struktur Variabel

Fitur: **18** | Target: **1 (Churn)**

03

Sumber Dataset

<https://www.kaggle.com/datasets/ankitverma2010/ecommerce-customer-churn-analysis-and-prediction>

Data Understanding

Deskripsi Dataset

Demografi & Profil Akun

CustomerID: Kode unik identitas setiap pelanggan.

Gender: Jenis kelamin pelanggan.

MaritalStatus: Status pernikahan pelanggan.

CityTier: Klasifikasi level kota tempat tinggal.

Tenure: Durasi pelanggan menggunakan layanan.

PreferredLoginDevice: Alat utama untuk masuk aplikasi.

PreferredPaymentMode: Metode pembayaran favorit.

Aktivitas & Penggunaan

HourSpendOnApp: Durasi waktu membuka aplikasi (jam).

NumberOfDeviceRegistered: Jumlah perangkat terdaftar.

NumberOfAddress: Jumlah alamat pengiriman disimpan.

WarehouseToHome: Jarak gudang barang ke rumah.

PreferredOrderCat: Kategori produk yang disukai.

SatisfactionScore: Rating kepuasan terhadap layanan.

Transaksi & Risiko Churn

OrderAmountHikeFromlastYear: % kenaikan nilai pesanan.

CouponUsed: Jumlah kupon belanja yang digunakan.

OrderCount: Jumlah total pesanan.

DaySinceLastOrder: Hari berlalu sejak transaksi terakhir.

CashbackAmount: Rata-rata nominal cashback bulanan.

Complain: Status pengajuan komplain bulan lalu.

Churn: Indikator berhenti menggunakan layanan.

Data Understanding

Quality Check

Duplikasi Data

Tidak ada duplikasi data

Cek Outlier (Metode Interquartile Range/IQR)

Fitur	Batas Atas	Batas Bawah	Jumlah outlier	% outlier	Nilai outlier (top 5)	Nilai outlier (bottom 5)
OrderCount	6.00	-2.00	703	13.09	[16.0, 16.0, 16.0, 16.0, 16.0]	[7.0, 7.0, 7.0, 7.0, 7.0]
CouponUsed	3.50	-0.50	629	11.70	[16.0, 16.0, 15.0, 14.0, 14.0]	[4.0, 4.0, 4.0, 4.0, 4.0]
CashbackAmount	272.33	69.84	438	7.78	[324.99, 324.99, 324.73, 324.73, 324.43]	[0.0, 0.0, 0.0, 0.0, 12.0]
NumberOfDeviceRegistered	5.50	1.50	397	7.05	[6, 6, 6, 6, 6]	[1, 1, 1, 1, 1]
DaySinceLastOrder	14.50	-5.50	62	1.16	[46.0, 31.0, 30.0, 18.0, 18.0]	[15.0, 15.0, 15.0, 15.0, 15.0]
OrderAmountHikeFromLastYear	25.50	5.50	33	0.62	[26.0, 26.0, 26.0, 26.0, 26.0]	[26.0, 26.0, 26.0, 26.0, 26.0]
HourSpendOnApp	4.50	0.50	6	0.11	[5.0, 5.0, 5.0, 0.0, 0.0]	[0.0, 0.0, 0.0, 5.0, 5.0]
Tenure	37.00	-19.00	4	0.07	[61.0, 60.0, 51.0, 50.0]	[50.0, 51.0, 60.0, 61.0]
NumberOfAddress	12.00	-4.00	4	0.07	[22, 21, 20, 19]	[19, 20, 21, 22]
WarehouseToHome	36.50	-7.50	2	0.04	[127.0, 126.0]	[126.0, 127.0]

Terdapat dua nilai ekstrem (outlier) pada fitur WarehouseToHome, yaitu 126 dan 127. Nilai outlier pada fitur lain tetap dianggap merepresentasikan perilaku pelanggan.


Missing Value

Fitur	Jumlah	Persentase (%)
Tenure	264	4.69
WarehouseToHome	251	4.46
HourSpendOnApp	255	4.53
OrderAmountHikeFromLastYear	265	4.71
CouponUsed	256	4.55
CouponUsed	258	4.58
DaySinceLastOrder	307	5.45

Data Understanding

Exploratory Data Analysis

Distribusi Churn




Kategori	Jumlah Data	Rate
Non-Churn = 0	4682	87,35%
Churn = 1	948	16,84%

Data Understanding


Exploratory Data Analysis

Distribusi Histogram Data Numerik



- Mayoritas pelanggan memiliki **tenure rendah 0-2 bulan**, jarak gudang ke rumah **di bawah 20km**, dan transaksi terakhir **< 10 hari**.
- Nominal **cashback** paling banyak terdistribusi di kisaran **150-200**.

Distribusi Bar Chart Data Numerik




- Pelanggan umumnya menghabiskan **~3 jam di platform** dan mendaftarkan **3-4 perangkat**.
- Mayoritas menggunakan **0-2 kupon**, menyimpan **2-3 alamat**, memesan **1-2 kali**, dengan kenaikan belanja **12-14%** dari tahun sebelumnya.

Data Understanding

Exploratory Data Analysis

Box Plot Data Numerik Terhadap Kondisi Churn




- Pelanggan churn cenderung memiliki **tenure lebih rendah**, **cashback lebih kecil**, serta **jarak rumah ke gudang sedikit lebih jauh**.
- Perbedaan paling kuat terlihat pada **tenure**.
- Sebagian besar fitur transaksi lainnya memiliki distribusi yang relatif serupa antara pelanggan churn dan tidak churn.

Data Understanding

Exploratory Data Analysis

Korelasi Spearman Fitur Data Numerik



- **Tenure** memiliki hubungan paling kuat dengan **churn (-0,40)**, menunjukkan bahwa pelanggan dengan masa hubungan lebih lama cenderung memiliki risiko churn lebih rendah.

- **DaySinceLastOrder** dan **CashbackAmount** juga berkorelasi negatif dengan churn, tetapi dengan hubungan yang lebih lemah.


- Antarfitur, korelasi tertinggi ditemukan pada **CouponUsed dan OrderCount (0,73)**, sehingga pelanggan yang melakukan lebih banyak pesanan cenderung menggunakan lebih banyak kupon.

- Sebagian besar hubungan lainnya tergolong dalam kategori **lemah hingga sedang**.

Data Understanding


Exploratory Data Analysis

Distribusi Data Kategorikal



- Pelanggan didominasi pengguna **mobile phone**, berasal dari **City Tier 1**, berjenis kelamin **laki-laki**, dan berstatus **menikah**.
- **Debit card** menjadi metode pembayaran utama.
- **Mobile phone dan laptop & accessory** merupakan kategori pesanan paling populer.
- Mayoritas rating kepuasan terhadap layanan paling di **nilai 3** dan pelanggan **tidak menyampaikan complain**.

Churn Rate Berdasarkan Data Kategorikal



- Churn paling banyak ditemukan pada pelanggan yang **pernah complain, berstatus single, memilih kategori Mobile Phone, serta menggunakan Cash on Delivery atau E-wallet**.
- Complain menunjukkan perbedaan paling kuat, dengan churn rate **sekitar 30%** dibandingkan **10%** pada pelanggan tanpa complain.

Data Preparation

Pre-Processing Data



Modeling

Metode Evaluasi Model

Confusion Matrix

	Predicted Positive (Churn)	Predicted Negative (Non-Churn)
Actual Positive (Churn)	True Positive (TP)	False Negative (FN)
Actual Negative (Non-Churn)	False Positive (FP)	True Negative (TN)

- **True Positive (TP)** → Pelanggan churn yang berhasil diprediksi sebagai churn

- **True Negative (TN)** → Pelanggan non-churn yang berhasil diprediksi sebagai non-churn

- **False Positive (FP)** → Pelanggan churn yang tidak diprediksi sebagai churn dan dianggap non-churn

- **False Negative (FN)** → Pelanggan non-churn yang tidak diprediksi sebagai non-churn dan dianggap churn

Metrik Evaluasi

Recall

$$= TP / (TP + FN)$$

Precision

$$= TP / (TP + FP)$$

F1-Score

$$= 2 \times (\text{Precision} \times \text{Recall}) / (\text{Precision} + \text{Recall})$$

PR-AUC

Precision Recall - Area Under Curve

Modeling

Baseline Model

Model	Konfigurasi Hyperparameter Tambahan	Mean K-Fold (K= 5) CV PR-AUC
Logistic Regression (LR)	class_weight='balanced' max_iter=2000, random_state=42	0.6979
Multi-layer Perceptron (MLP)	max_iter=1000, random_state=42	0.9205
Random Forest (RF)	class_weight='balanced', random_state=42	0.9250
XGBoost	scale_pos_weight=spw, random_state=42	0.9157
LightGBM	class_weight='balanced', random_state=42	0.9129
CatBoost	auto_class_weights='Balanced', random_seed=42	0.9046

- Baseline model menggunakan **default parameter** masing - masing model
- MLP menggunakan RandomOversampler untuk menangani imbalance.

Modeling

Optimasi Parameter Model Menggunakan GridSearch

Model	Hyperparameter	Konfigurasi Nilai	Nilai Terbaik	Mean K-Fold (K= 5) CV PR-AUC
LR	C	[0.01, 0.1, 1, 10, 100]	0.01	0.7056
MLP	hidden_layer_sizes	[(64,), (100,), (128,), (64,32), (128,64)]	(100,)	0.9575
	alpha	[0.0001, 0.001, 0.01]	0.001	
	learning_rate_init	[0.001, 0.01]	0.01	
	activation	[relu, tanh]	tanh	
RF	n_estimators	[100, 200, 400, 600]	600	0.9307
	max_depth	[None, 10, 20, 30]	20	
	min_samples_split	[2, 5, 10]	2	
	max_features	[sqrt, log2]	log2	

Modeling

Optimasi Parameter Model Menggunakan GridSearch

Model	Hyperparameter	Konfigurasi Nilai	Nilai Terbaik	Mean K-Fold (K= 5) CV PR-AUC
XGBoost	n_estimators	[100, 200, 400, 600]	600	0.9287
	max_depth	[3, 6, 9]	9	
	learning_rate	[0.03, 0.05, 0.1, 0.3]	0.03	
	subsample	[0.8, 1]	0.8	
	colsample_bytree	[0.8, 1]	0.8	
CatBoost	iterations	[200, 400, 600, 1000]	1000	0.9502
	depth	[4, 6, 8]	8	
	l2_leaf_reg	[1, 3, 5]	1	
	learning_rate	[0.01, 0.03, 0.05, 0.1]	0.05	

Modeling


Optimasi Parameter Model Menggunakan GridSearch

Model	Hyperparameter	Konfigurasi Nilai	Nilai Terbaik	Mean K-Fold (K= 5) CV PR-AUC
LightGBM	n_estimators	[100, 200, 400, 600]	600	0.9455
	num_leaves	[31, 63, 127]	127	
	learning_rate	[0.03, 0.05, 0.1]	0.05	
	bagging_fraction	[0.8, 1]	1	
	bagging_freq	[1]	1	
	min_data_in_leaf	[10, 20, 40]	20	

Seluruh model di optimasi menggunakan GridSearch berdasarkan skor evaluasi PR-AUC

Evaluation

Dampak Optimasi Hyperparameter



- Secara keseluruhan, seluruh **model mengalami peningkatan performa** setelah dilakukan Grid Search.
- Peningkatan tersebut menunjukkan bahwa model dapat **mengurutkan dan memprioritaskan pelanggan yang benar-benar berisiko churn**.

Evaluation

Evaluasi Akhir Model – Baseline


Model	PR-AUC	Recall	Precision	F1-Score
LR	0.6880	0.8310	0.4461	0.5806
MLP	0.9751	0.9261	0.9634	0.9443
RF	0.9664	0.9225	0.9291	0.9258
XGBoost	0.9663	0.9296	0.9362	0.9329
LightGBM	0.9520	0.9261	0.8376	0.8796
CatBoost	0.9558	0.9437	0.8349	0.8860



Evaluation

Evaluasi Akhir Model - Tuning Grid Search

Model	PR-AUC	Recall	Precision	F1-Score
MLP	0.9931	0.9472	0.9818	0.9642
CatBoost	0.9861	0.9401	0.9468	0.9435
LightGBM	0.9776	0.9049	0.9519	0.9278
XGBoost	0.9715	0.9261	0.9495	0.9376
RF	0.9685	0.9120	0.9350	0.9234
LR	0.6902	0.8204	0.4283	0.5628



Best Model: Multi-layer Perceptron (MLP)

PR-AUC tertinggi sehingga dapat **memprioritaskan pelanggan yang paling beresiko churn**, recall tertinggi sehingga dapat **mendeteksi sebagian besar pelanggan yang berisiko churn** sebelum mereka pergi, precision tertinggi sehingga **deteksi churn lebih tepat sasaran**, dan F1-Score yang tertinggi sehingga model dapat menemukan **keseimbangan antara deteksi churn dengan ketepatan target pelanggan churn**. Model berhasil mengidentifikasi 269 dari 284 pelanggan churn, dengan 15 kesalahan prediksi churn (false positive) dan 5 kesalahan prediksi non-churn (false negative).

Evaluation


Analisis SHAP Model MLP

Interpretasi Model Secara Global – Beeswarm Plot

- **Tenure rendah cenderung meningkatkan prediksi churn**
→ **Tenure** rendah ditunjukkan oleh titik biru berada di sisi nilai SHAP positif.
- **Riwayat komplain cenderung meningkatkan prediksi churn**
→ **Complain_1 = 1** lebih banyak berada di sisi SHAP positif
- **Preferensi terhadap kategori Laptop & Accessory cenderung menurunkan prediksi churn**
→ **PreferredOrderCat_Laptop & Accessory = 1** lebih banyak berada di sisi SHAP negatif

Keterangan Plot:

- **Sumbu X:** Nilai SHAP | **Sumbu Y:** Fitur
- **SHAP Positif** → Prediksi mengarah ke **Churn** | **SHAP Negatif** → Prediksi mengarah ke **Non-Churn**
- **Merah** = Nilai Fitur Tinggi | **Biru** = Nilai Fitur Rendah



Evaluation


Analisis SHAP Model MLP

Interpretasi Model Secara Global – Feature Importance

- 3 fitur utama yang memiliki kontribusi terbesar terhadap output model adalah **Tenure**, **Complain_1**, dan **PreferredOrderCat_Laptop & Accessory** karena memiliki mean absolute SHAP tertinggi.
- Model banyak memanfaatkan informasi mengenai durasi pelanggan, riwayat complain, dan preferensi kategori pesanan laptop & accessory.
- Beberapa fitur seperti **PreferredOrderCat_Others**, **SatisfactionScore_2**, dan **PreferredOrderCat_Grocery** memiliki kontribusi global yang relatif rendah terhadap output model.

Keterangan Plot:

- **Sumbu X:** Mean absolute SHAP | **Sumbu Y:** Fitur




Evaluation

Analisis SHAP Model MLP

Interpretasi Model Secara Lokal (Individual) – Waterfall Plot

Contoh output pada 1 sampel pelanggan acak dengan probabilitas churn 99.62%. Berikut 3 faktor utama yang meningkatkan prediksi pelanggan churn pelanggan tersebut:

- **City_Tier3 = 1**, dengan SHAP positif
→ Pelanggan bertempat tinggal di wilayah City Tier 3. Hal tersebut berkontribusi meningkatkan prediksi churn.
- **PreferredOrderCat_Laptop & Accessory = 0**, dengan SHAP positif
→ Laptop & Accessory bukan kategori pesanan yang paling dipilih pelanggan. Hal tersebut berkontribusi meningkatkan prediksi churn.
- **PreferredPaymentMode_Credit Card = 1**, SHAP positif
→ Credit Card merupakan metode pembayaran yang paling disukai pelanggan. Hal tersebut berkontribusi meningkatkan prediksi churn.



Keterangan Plot:

- **SHAP Positif (Merah)** → Meningkatkan churn
- **SHAP Negatif (Biru)** → Menurunkan churn
- **$f(x)$** → Probabilitas churn
- **$E[f(X)]$** → Probabilitas churn baseline


Evaluation

Analisis SHAP Model MLP

Interpretasi Model Secara Lokal (Individual) – Waterfall Plot

Contoh output pada 1 sampel pelanggan acak dengan probabilitas churn $\approx 0\%$. Berikut 3 faktor utama yang meningkatkan prediksi pelanggan bertahan (non-churn):

- **PreferredOrderCat_Laptop & Accessory = 1**, dengan SHAP negatif
→ Laptop & Accessory merupakan kategori pesanan yang paling dipilih pelanggan. Hal tersebut berkontribusi menurunkan prediksi churn.
- **NumberOfAddress = 1**, dengan SHAP negatif
→ Jumlah alamat yang tersimpan sejumlah satu. Hal tersebut berkontribusi menurunkan prediksi churn.
- **Complain_1 = 0**, dengan SHAP negatif
→ Pelanggan tidak pernah complain berkontribusi menurunkan probabilitas churn.



Keterangan Plot:

- **SHAP Positif (Merah)** → Meningkatkan churn
- **SHAP Negatif (Biru)** → Menurunkan churn
- **$f(x)$** → Probabilitas churn
- **$E[f(x)]$** → Probabilitas churn baseline

Evaluation

Analisis SHAP Model MLP


Dependence Plot Complain dan Tenure

- **Riwayat komplain meningkatkan prediksi churn**

→ Pelanggan yang pernah komplain mayoritas memiliki nilai SHAP positif (meningkatkan prediksi churn), sedangkan pelanggan tanpa komplain didominasi nilai SHAP negatif.

- **Dampak komplain cenderung lebih tinggi pada pelanggan tenure rendah**

→ Pelanggan yang tidak bertahan lama (tenure ↓) memiliki nilai SHAP lebih tinggi, sehingga kontribusi komplain terhadap prediksi churn cenderung lebih besar.



Keterangan Plot:

- Sumbu-x → 0 = tidak komplain | 1 = komplain
- Sumbu-y → Nilai SHAP Complain_1
- Merah = Tenure tinggi | Biru = Tenure rendah

Conclusion

01 MLP menjadi model terbaik untuk memprediksi pelanggan churn dengan PR-AUC sebesar 0.9931, recall 0.9472, precision 0.9818, dan F1-score 0.9642. Model berhasil mengidentifikasi 269 dari 284 pelanggan churn, dengan 15 false positive dan 6 false negative.

02 Berdasarkan analisis SHAP model MLP, fitur Tenure, Complain_1, dan PreferredOrderCat_Laptop & Accessory memiliki kontribusi global terbesar terhadap output model. Tenure rendah dan pernah komplain cenderung meningkatkan prediksi churn, sedangkan preferensi terhadap kategori Laptop & Accessory cenderung menurunkan prediksi churn.

Deployment

Link: <https://churn-prediction-ecommerce.streamlit.app/>

Tentang aplikasi
Aplikasi ini digunakan untuk memprediksi kemungkinan pelanggan berhenti menggunakan layanan e-commerce (churn).

Cara pakai
1. Isi data pelanggan
2. Klik Prediksi
3. Lihat hasil & faktor yang meningkatkan hasil prediksinya

Data pelanggan

Lama berlangganan (bulan)	Pernah komplain
1	Ya
Tarif data	Kapasitas baterai (%)
1	33
Jarak pulang ke rumah (km)	Jumlah kupon dipakai
15	1
Jam pakai aplikasi per hari	Jumlah pesanan
3	2
Jumlah perangkat terdaftar	Harap sejah pesanan terakhir
3	5

Portofolio project: Khalidha Haqira Zahra - 2020


Tentang aplikasi
Aplikasi ini digunakan untuk memprediksi kemungkinan pelanggan berhenti menggunakan layanan e-commerce (churn).

Cara pakai
1. Isi data pelanggan
2. Klik Prediksi
3. Lihat hasil & faktor yang meningkatkan hasil prediksinya

Detail hasil

Skor keapusan: 3
Nilai cashback: 150
Jumlah alamat terapan: 3
Perangkat login: Mobile Phone
Metode pembayaran: E-wallet
Jenis kelamin: Female
Kategori barang: Mobile Phone
Status pernikahan: Single

Portofolio project: Khalidha Haqira Zahra - 2020



Referensi

- Chajia, M., Nfaoui, E. H., & Ouali, S. (2026). Analyzing the Impact of Feature Selection on Customer Churn Prediction in the Retail E-Commerce Industry. *AI*, 7(7), 244. <https://doi.org/10.3390/ai7070244>.
- Fauziyyah, N. H., Sudiarsa, I. W., Sastradewi, I. A. E., Parisya, K. A. Y., & Sartika, S. (2026). Analisis Prediksi Customer Churn pada Sektor E-Commerce Berdasarkan Perilaku Transaksi Menggunakan Pendekatan Machine Learning. *Jurnal Manajemen Bisnis Digital Terkini*, 3(1), 300–318. <https://doi.org/10.61132/jumbidter.v3i1.1228>.
- Ecommerce Customer Churn Analysis and Prediction. <https://www.kaggle.com/datasets/ankitverma2010/ecommerce-customer-churn-analysis-and-prediction>.

Thanks!

Thank You!

Thanks!

